

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP
KHOA ĐIỆN TỬ



BÁO CÁO BÀI TẬP LỚN
MÔN HỌC : KHOA HỌC DỮ LIỆU

Sinh viên thực hiện : ĐẶNG ĐÌNH ĐẠT

MSV : K225480106003

Lớp : K58KTPM

GVHD : Ts. NGUYỄN VĂN HUY

Thái nguyên 2026

TRƯỜNG ĐHKTCN

CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM

KHOA ĐIỆN TỬ

Độc lập - Tự do - Hạnh phúc

BM THCN

PHIẾU GIAO NHIỆM VỤ

MÔN HỌC : KHOA HỌC DỮ LIỆU

Sinh viên : Đặng Đình Đạt

MSSV:k225480106003 Lớp:58KTMT

Ngành học: Kỹ thuật máy tính

Giáo viên hướng dẫn: **Ts.Nguyễn Văn Huy**

1.Nội dung

Phân tích dữ liệu đặt xe công nghệ

- Khung giờ nào có nhiều chuyến đi nhất?
- Ngày nào trong tuần đông khách nhất?
- Khu vực nào có nhu cầu cao nhất?
- Quãng đường trung bình của mỗi chuyến?
- Mối quan hệ giữa thời gian và số chuyến đi?
- Dự đoán số chuyến xe trong giờ tiếp theo.
- Phân cụm các khu vực có nhu cầu tương đồng.

2. Ngày giao nhiệm vụ: ngày 01 tháng 06 năm 2026

3. Ngày hoàn thành nhiệm vụ: ngày 28 tháng 06 năm 2026

GIÁO VIÊN GIẢNG GIÀY

Ts. Nguyễn Văn Huy

NHẬN XÉT CỦA GIÁO VIÊN GIẢNG GIÀY

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Thái Nguyên, ngày... tháng... năm 2026

GIÁO VIÊN GIẢNG DẠY

MỤC LỤC

MỤC LỤC	1
DANH MỤC TỪ VIẾT TẮT	3
DANH MỤC HÌNH ẢNH.....	4
CHƯƠNG 1: TỔNG QUAN VÀ MỞ ĐẦU	6
1.1 Đặt vấn đề và Lý do chọn đề tài	6
1.2 Mục tiêu và Câu hỏi nghiên cứu.....	7
1.3 Đối tượng, Phạm vi và Giới hạn nghiên cứu.....	8
<i>Tóm tắt Chương 1</i>	9
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU.....	10
2.1 Tổng quan về Quy trình Phân tích Khoa học Dữ liệu	10
2.2 Phương pháp Học Không giám sát: K-Means Clustering	11
2.3 Phương pháp Học Có giám sát: Gradient Boosting Regressor	12
2.4 Công cụ và Thư viện lập trình	13
<i>Tóm tắt Chương 2</i>	14
CHƯƠNG 3: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN	15
3.1 Phân tích thống kê mô tả: Hiểu về hành vi người dùng	15
3.1.1 Phân tích chu kỳ nhu cầu theo khung giờ trong ngày	15
3.1.2 Phân bố lưu lượng xe theo các ngày trong tuần	16
3.1.3 Trực quan hóa dữ liệu không gian và địa lý (Spatial Analysis)	17
3.1.4 Khảo sát phân phối cự ly di chuyển	19
3.1.5 Mối quan hệ tương quan Giờ - Ngày bằng Heatmap	20
3.2 Ứng dụng Học Máy (Machine Learning) trong phân tích sâu	21
3.2.1 Xây dựng mô hình dự đoán nhu cầu bằng Gradient Boosting Regressor	21
3.2.2 Phân cụm Surge Pricing bằng Thuật toán K-Means Clustering.....	23
<i>Tóm tắt Chương 3</i>	24
CHƯƠNG 4: KẾT LUẬN VÀ KIẾN NGHỊ GIẢI PHÁP	25
4.1 Kết luận chung.....	25

4.2 Kiến nghị giải pháp mang tính chiến lược	25
TÀI LIỆU THAM KHẢO	27

DANH MỤC TỪ VIẾT TẮT

TP.HCM	Thành phố Hồ Chí Minh
ML	Machine Learning (Học máy)
KHDL	Khoa học Dữ liệu
MAE	Mean Absolute Error (Sai số tuyệt đối trung bình)
R2 Score	Hệ số xác định (R-Squared)
AI	Artificial Intelligence (Trí tuệ nhân tạo)
EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
GBR	Gradient Boosting Regressor

DANH MỤC HÌNH ẢNH

Hình 3.1: Biểu đồ số chuyến đi theo khung giờ

Hình 3.2: Phân bố số chuyến đi theo ngày trong tuần

Hình 3.3: Nhu cầu đặt xe theo từng Quận/Huyện

Hình 3.4: Phân phối quãng đường các chuyến đi

Hình 3.5: Mối quan hệ giữa thời gian và số chuyến (Heatmap)

Hình 3.6: Kết quả dự đoán số lượng chuyến xe

Hình 3.7: Phân cụm các khu vực theo K-Means

LỜI CẢM ƠN

Trong quá trình học tập và nghiên cứu môn học Khoa học Dữ liệu, em đã nhận được sự quan tâm, giúp đỡ, hướng dẫn vô cùng tận tình của Thầy/Cô Khoa Điện Tử. Em xin gửi lời cảm ơn sâu sắc nhất đến Giảng viên hướng dẫn môn học Ts: Nguyễn Văn Huy, người đã trực tiếp truyền đạt những kiến thức quý báu, từ nền tảng lý thuyết phân tích thống kê cho đến các mô hình học máy phức tạp, đồng thời luôn hỗ trợ và định hướng để em hoàn thành bài báo cáo nghiên cứu khoa học này.

Sự bùng nổ của kỷ nguyên dữ liệu lớn (Big Data) đòi hỏi sinh viên không chỉ nắm vững lý thuyết mà còn phải có khả năng áp dụng công cụ vào giải quyết các bài toán thực tiễn. Đề tài "Nghiên cứu phân tích và khai thác dữ liệu đặt xe công nghệ tại TP.HCM" là cơ hội tuyệt vời để em vận dụng toàn bộ những gì đã học về Pandas, Numpy, Scikit-Learn và các kỹ thuật trực quan hóa dữ liệu. Qua quá trình thực hiện, em đã rèn luyện được tư duy hệ thống, kỹ năng lập trình và cách biến những con số vô tri thành những thông tin mang giá trị chiến lược (business insights).

Mặc dù đã có nhiều nỗ lực trong việc tìm kiếm tài liệu, xử lý dữ liệu và xây dựng mô hình học máy, nhưng do giới hạn về mặt thời gian cũng như kiến thức chuyên môn của một sinh viên, bài báo cáo này khó tránh khỏi những thiếu sót và hạn chế nhất định. Em rất mong nhận được những lời nhận xét, đánh giá và đóng góp ý kiến từ Quý Thầy/Cô để đề tài được hoàn thiện hơn, đồng thời giúp em rút ra những bài học kinh nghiệm quý giá cho con đường học tập và nghiên cứu sau này.

Một lần nữa, em xin gửi lời cảm ơn chân thành và lời chúc sức khỏe, thành công đến toàn thể Quý Thầy/Cô!

CHƯƠNG 1: TỔNG QUAN VÀ MỞ ĐẦU

1.1 Đặt vấn đề và Lý do chọn đề tài

Sự phát triển mạnh mẽ của công nghệ thông tin và truyền thông trong thập kỷ qua đã tạo ra một cuộc cách mạng trong lĩnh vực giao thông vận tải, đặc biệt là sự ra đời và bùng nổ của các nền tảng gọi xe công nghệ (ride-hailing platforms) như Grab, Be, Gojek. Tại các siêu đô thị như Thành phố Hồ Chí Minh (TP.HCM), nơi có mật độ dân cư đông đúc và mạng lưới giao thông vô cùng phức tạp, các dịch vụ gọi xe công nghệ đã nhanh chóng trở thành một phần không thể thiếu trong cuộc sống hàng ngày của hàng triệu người dân. Sự chuyển dịch từ phương tiện cá nhân và taxi truyền thống sang các ứng dụng gọi xe không chỉ làm thay đổi thói quen di chuyển mà còn tạo ra một lượng dữ liệu khổng lồ (Big Data) mỗi ngày.

Mỗi chuyến xe được thực hiện đều để lại một dấu vết dữ liệu số, bao gồm tọa độ điểm đón, điểm đến, thời gian bắt đầu, thời gian kết thúc, cự ly di chuyển, và thậm chí là thông tin về điều kiện giao thông tại thời điểm đó. Tập dữ liệu này chứa đựng những thông tin vô giá phản ánh trực tiếp hành vi di chuyển của người dân, quy luật tắc nghẽn giao thông, sự phân bố dân cư và nhu cầu vận tải tại các khu vực khác nhau trong đô thị. Tuy nhiên, nếu chỉ tồn tại dưới dạng những con số thô (raw data), lượng dữ liệu khổng lồ này sẽ không mang lại bất kỳ giá trị thực tiễn nào. Vấn đề cốt lõi đặt ra đối với các doanh nghiệp cung cấp dịch vụ gọi xe và các nhà quản lý đô thị là làm thế nào để khai phá, phân tích và biến những dữ liệu thô này thành tri thức (knowledge) và thông tin tình báo kinh doanh (business intelligence).

Trong bối cảnh cạnh tranh gay gắt, việc điều phối tài xế một cách hiệu quả là yếu tố sống còn. Một trong những bài toán đau đầu nhất của các hãng xe công nghệ là hiện tượng "lệch pha cung - cầu" cục bộ. Tại một số khu vực trung tâm vào giờ cao điểm, lượng khách hàng có nhu cầu gọi xe tăng đột biến vượt quá số lượng tài xế có sẵn, dẫn đến thời gian chờ đợi lâu và tỷ lệ hủy chuyến cao. Ngược lại, tại các khu vực ven đô hoặc vào các khung giờ thấp điểm, nhiều tài xế phải chạy xe không tải hoặc nằm chờ hàng giờ đồng hồ gây lãng phí nhiên liệu và giảm thu nhập.

Để giải quyết bài toán này, Khoa học dữ liệu (Data Science) và Học máy (Machine Learning) là chìa khóa. Việc áp dụng các kỹ thuật Phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA) giúp chúng ta hình dung bức tranh tổng thể về nhu cầu theo thời gian và không gian. Hơn thế nữa, các thuật toán Học máy như phân cụm K-Means và dự đoán Gradient Boosting có thể giúp dự báo trước nhu cầu trong tương lai và xác định chính xác các điểm nóng giao thông. Khi hệ thống có khả năng dự đoán nhu cầu tại một khu vực cụ thể sẽ tăng vọt trong 30 phút tới, hãng xe có thể chủ động điều hướng tài xế di chuyển về khu vực đó trước khi nhu cầu thực sự xảy ra, hoặc kích hoạt hệ thống tăng giá động (Surge Pricing) để cân bằng cung cầu.

Xuất phát từ những vấn đề thực tiễn mang tính cấp thiết và giá trị ứng dụng cao, em đã quyết định chọn đề tài "Nghiên cứu phân tích và khai thác dữ liệu đặt xe công nghệ tại TP.HCM: Ứng dụng mô hình học máy trong điều phối và dự đoán nhu cầu giao thông đô thị" làm báo cáo nghiên cứu khoa học cuối kỳ. Đề tài không chỉ là cơ hội để vận dụng tổng hợp các kiến thức đã học về lập trình Python, phân tích thống kê, trực quan hóa dữ liệu mà còn giúp em tiếp cận với quy trình giải quyết một bài toán dữ liệu thực tế trong môi trường kinh doanh hiện đại. Khát vọng của nghiên cứu này là đề xuất những mô hình phân tích có tính hệ thống, góp phần cung cấp góc nhìn sâu sắc về bức tranh giao thông đô thị dựa trên dữ liệu.

1.2 Mục tiêu và Câu hỏi nghiên cứu

Mục tiêu tổng quát của đề tài là xây dựng một quy trình khai phá dữ liệu đầu cuối (end-to-end data mining pipeline), từ việc tiền xử lý dữ liệu thô, phân tích thống kê mô tả, đến việc triển khai các mô hình học máy tiên tiến nhằm tìm ra quy luật di chuyển và dự báo nhu cầu đặt xe công nghệ tại khu vực TP.HCM.

Để đạt được mục tiêu tổng quát trên, nghiên cứu đặt ra các mục tiêu cụ thể và tương ứng với đó là các câu hỏi nghiên cứu cốt lõi cần phải giải quyết:

- **Thứ nhất:** mục tiêu về phân tích đặc điểm thời gian của nhu cầu đi lại: Xác định các khoảng thời gian có lưu lượng đặt xe cao nhất và thấp nhất trong chu kỳ một ngày và một tuần. Câu hỏi nghiên cứu đặt ra là: "Khung giờ nào trong ngày có nhiều chuyến đi nhất?" và "Ngày nào trong tuần là ngày đông khách

nhất?". Việc trả lời các câu hỏi này giúp doanh nghiệp tối ưu hóa kế hoạch làm việc của nhân sự vận hành hệ thống.

- **Thứ hai:** mục tiêu về phân tích đặc điểm không gian và định lượng hành vi: Lập bản đồ phân bố các điểm đón khách trên địa bàn thành phố và tính toán phân phối chiều dài các chuyến đi. Câu hỏi nghiên cứu: "Khu vực nào tại TP.HCM có nhu cầu cao nhất?" và "Quãng đường trung bình của một chuyến xe là bao nhiêu?". Việc thấu hiểu quãng đường di chuyển giúp tối ưu hóa thuật toán tính giá và đánh giá hiệu suất của tài xế.
- **Thứ ba:** mục tiêu về khai phá mối tương quan không gian - thời gian: Phát hiện sự thay đổi về nhu cầu giữa các khung giờ theo từng ngày khác nhau trong tuần. Câu hỏi nghiên cứu: "Mối quan hệ giữa thời gian trong ngày và ngày trong tuần ảnh hưởng thế nào đến tổng số chuyến đi?".
- **Thứ tư:** mục tiêu về mô hình hóa học máy (Machine Learning Modeling): Xây dựng mô hình học có giám sát để dự đoán cầu và mô hình học không giám sát để định vị không gian. Câu hỏi nghiên cứu: "Làm thế nào để dự đoán chính xác số lượng chuyến xe trong giờ tiếp theo bằng thuật toán Gradient Boosting?" và "Làm thế nào để phân vùng bản đồ TP.HCM thành các cụm nhu cầu dựa trên tọa độ thực tế bằng thuật toán K-Means Clustering nhằm phục vụ chiến lược Surge Pricing?".

Mỗi mục tiêu đều được hiện thực hóa bằng các dòng code cụ thể, từ khâu làm sạch dữ liệu bằng Pandas, trực quan hóa bằng Seaborn đến việc tối ưu hóa siêu tham số cho các mô hình của thư viện Scikit-Learn. Kết quả thu được sẽ là các phân tích định lượng làm cơ sở cho mọi lập luận kinh doanh.

1.3 Đối tượng, Phạm vi và Giới hạn nghiên cứu

Đối tượng nghiên cứu chính của đề tài là dữ liệu hành vi gọi xe của người dùng thông qua các ứng dụng công nghệ, được biểu diễn qua các đặc trưng về thời gian, không gian và định lượng quãng đường.

- **Phạm vi nghiên cứu không gian:** Đề tài giới hạn phân tích các chuyến đi được khởi hành tại khu vực nội thành Thành phố Hồ Chí Minh, tập trung chủ yếu vào

các quận trọng điểm có mật độ giao thông lớn như Quận 1, Quận 3, Tân Bình, Quận 2 (thành phố Thủ Đức) và Quận 7. Đây là những khu vực đại diện cho trung tâm hành chính, thương mại và các khu dân cư sầm uất.

- **Phạm vi nghiên cứu thời gian:** Dữ liệu được thu thập và mô phỏng phản ánh các chuyến đi diễn ra trong khoảng thời gian từ tháng 4 năm 2024 đến tháng 9 năm 2024. Khoảng thời gian nửa năm là đủ lớn để triệt tiêu các yếu tố nhiễu cục bộ và làm nổi bật lên các xu hướng, quy luật di chuyển có tính chu kỳ tuần hoàn (seasonality).
- **Giới hạn của nghiên cứu:** Do đặc thù bảo mật thông tin từ các tập đoàn công nghệ (Grab, Be, Gojek), tập dữ liệu được sử dụng trong bài báo cáo này là tập dữ liệu mô phỏng (simulated dataset) dựa trên cấu trúc của tập dữ liệu Uber Trip Dataset nổi tiếng tại New York, kết hợp với các tri thức chuyên gia về địa lý và quy mô giao thông tại TP.HCM. Việc mô phỏng dữ liệu tuân thủ nghiêm ngặt các quy luật thống kê phân phối để đảm bảo mô hình phản ánh sát nhất với thực tế. Tuy nhiên, kết quả phân tích có thể thay đổi trong điều kiện dữ liệu vận hành thực (live data) có bao gồm các yếu tố thời tiết, sự kiện lễ hội hay biến động kinh tế vĩ mô. Nghiên cứu cũng chưa xét đến yếu tố giá cước cụ thể (fare amount) do độ phức tạp trong chính sách giá của từng hãng.

Tóm tắt Chương 1

Chương 1 đã phác thảo một cách toàn diện bối cảnh của đề tài nghiên cứu. Sự phát triển bùng nổ của dịch vụ gọi xe công nghệ tại TP.HCM đã tạo ra nguồn dữ liệu dồi dào nhưng cũng đặt ra bài toán thách thức về điều phối và định giá (Surge Pricing). Đề tài được lựa chọn với mục tiêu rõ ràng là áp dụng Khoa học dữ liệu và Học máy (K-Means, Gradient Boosting) để hiểu rõ hành vi người dùng theo không gian, thời gian và hỗ trợ ra quyết định. Đối tượng nghiên cứu xoay quanh tập dữ liệu chuyến đi tại 5 quận trọng điểm trong thời gian 6 tháng. Đây là cơ sở vững chắc để bước vào các khâu phân tích kỹ thuật và lý thuyết ở các chương tiếp theo.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1 Tổng quan về Quy trình Phân tích Khoa học Dữ liệu

Khoa học dữ liệu (Data Science) là một lĩnh vực đa ngành kết hợp giữa thống kê học, toán học ứng dụng, khoa học máy tính và kiến thức chuyên ngành (domain knowledge) nhằm trích xuất các tri thức hữu ích từ dữ liệu. Quá trình thực hiện nghiên cứu tuân thủ theo quy trình chuẩn mực CRISP-DM (Cross-Industry Standard Process for Data Mining) được rút gọn phù hợp với quy mô đề tài, bao gồm các giai đoạn cốt lõi:

1. **Thu thập và Hiểu dữ liệu (Data Understanding):** Nhằm bắt các trường dữ liệu (columns), kích thước tập dữ liệu, định dạng kiểu dữ liệu và ý nghĩa kinh doanh của từng biến số.
2. **Tiền xử lý và Làm sạch dữ liệu (Data Preprocessing & Cleaning):** Đây là giai đoạn tiêu tốn nhiều thời gian nhất. Các công việc bao gồm kiểm tra và xử lý dữ liệu bị thiếu (missing values), xử lý dữ liệu ngoại lai (outliers), và chuẩn hóa định dạng văn bản, đặc biệt là chuyển đổi các chuỗi ký tự thời gian (String) sang định dạng đối tượng Thời gian (Datetime Object) để phục vụ cho các tính toán mốc thời gian.
3. **Kỹ nghệ Đặc trưng (Feature Engineering):** Các thuật toán học máy không thể tự động hiểu được một đối tượng Datetime chứa ngày tháng năm giờ phút. Chúng ta phải thực hiện Feature Engineering để bóc tách một biến phức tạp thành nhiều biến đơn giản mang ý nghĩa phân loại. Trong nghiên cứu này, cột thời gian gốc được phân rã thành các đặc trưng mới như "Giờ trong ngày" (0-23), "Ngày trong tuần" (Thứ Hai đến Chủ Nhật) và "Tháng". Việc này mang lại giá trị cực kỳ lớn, vì hành vi bắt xe lúc 8h sáng chắc chắn khác biệt hoàn toàn so với lúc 2h đêm.
4. **Xây dựng mô hình (Modeling):** Lựa chọn, áp dụng các thuật toán máy học phù hợp với bài toán (Phân loại, Hồi quy, Phân cụm). Tiến hành huấn luyện mô hình (Training) dựa trên tập dữ liệu đã chia.

5. **Đánh giá (Evaluation):** Đo lường độ chính xác của mô hình bằng các độ đo tiêu chuẩn để đảm bảo tính khách quan và tính tổng quát hóa trước khi triển khai.

2.2 Phương pháp Học Không giám sát: K-Means Clustering

Trong bối cảnh hệ thống gọi xe công nghệ, nhu cầu gọi xe tại các địa điểm trên bản đồ không phân bố đồng đều mà tạo thành các "điểm nóng" (Hotspots). Việc nhóm các điểm tọa độ liên kề có cùng mức độ nhu cầu lại với nhau là một bài toán Phân cụm (Clustering). Phân cụm thuộc nhóm Học không giám sát (Unsupervised Learning) vì dữ liệu đưa vào hoàn toàn không có nhãn (label) định sẵn.

K-Means Clustering là một trong những thuật toán phân cụm kinh điển và hiệu quả nhất. Chữ "K" biểu thị số lượng cụm (clusters) mong muốn được phân chia. Thuật toán hoạt động dựa trên việc tối thiểu hóa tổng bình phương khoảng cách từ mỗi điểm dữ liệu đến tâm của cụm (centroid) mà điểm đó thuộc về. Cụ thể, thuật toán trải qua các bước lặp (iterations) như sau:

- Bước 1 - Khởi tạo tâm cụm (Initialization): Chọn ngẫu nhiên K điểm từ không gian dữ liệu để làm tâm cụm ban đầu. Việc khởi tạo có thể dùng phương pháp K-Means++ để phân tán các tâm cụm ban đầu ra xa nhau, giúp tránh việc hội tụ vào cực tiểu cục bộ (local minima).
- Bước 2 - Gán cụm (Assignment): Tính toán khoảng cách (thường dùng khoảng cách Euclidean) từ từng điểm dữ liệu trong tập đến K tâm cụm. Điểm dữ liệu sẽ được gán (assign) vào cụm có tâm gần với nó nhất. Lúc này, không gian dữ liệu đã được chia thành K vùng.
- Bước 3 - Cập nhật tâm cụm (Update): Đối với mỗi cụm vừa được hình thành, thuật toán tiến hành tính toán lại vị trí trung bình (mean) của tất cả các tọa độ điểm dữ liệu nằm trong cụm đó. Vị trí trung bình mới này sẽ trở thành tâm cụm (centroid) mới của cụm.
- Bước 4 - Hội tụ (Convergence): Lặp lại Bước 2 và Bước 3 liên tục. Thuật toán sẽ dừng lại khi sự dịch chuyển của các tâm cụm sau bước cập nhật nhỏ hơn một

ngưỡng cho trước (tolerance) hoặc số vòng lặp vượt quá giới hạn cực đại (max iterations).

Trong nghiên cứu này, việc xác định số cụm K là một quyết định mang tính chiến lược. Nếu K quá nhỏ, các khu vực sẽ không được phân loại đủ mịn. Nếu K quá lớn, thuật toán sẽ chia bản đồ thành những vùng quá nhỏ lẻ, không mang ý nghĩa thực tiễn cho việc điều hành. Doanh nghiệp cần nhóm bản đồ thành 3 mức độ giá: Tăng cao, Tăng nhẹ và Không tăng. Dựa trên phân tích địa lý của TP.HCM và yêu cầu quản lý, K=3 (Tương đương 3 mức: Nhu cầu Cao, Trung bình, Thấp) đã được lựa chọn.

2.3 Phương pháp Học Có giám sát: Gradient Boosting Regressor

Dự đoán số lượng chuyến xe trong một giờ nhất định là bài toán Hồi quy (Regression) thuộc nhóm Học có giám sát (Supervised Learning), vì chúng ta đã có sẵn nhãn (số lượng chuyến xe thực tế trong quá khứ) để mô hình học tập.

Khi mối quan hệ giữa biến đầu vào (như thời gian, thứ trong tuần) và biến mục tiêu (số chuyến xe) phức tạp và hoàn toàn phi tuyến tính, các mô hình Hồi quy tuyến tính (Linear Regression) truyền thống sẽ thất bại do hiện tượng Underfitting. Thay vào đó, thuật toán Gradient Boosting Regressor nổi lên như một công cụ tối ưu hàng đầu.

Gradient Boosting là một kỹ thuật Học kết hợp (Ensemble Learning). Thay vì cố gắng tạo ra một mô hình đơn lẻ khổng lồ và phức tạp, Ensemble Learning tạo ra hàng trăm mô hình dự đoán yếu (Weak Learners), thường là các Cây quyết định (Decision Trees) có độ sâu rất nông. Quá trình kết hợp của Gradient Boosting (thuộc họ Boosting) là quá trình kết hợp tuần tự (Sequential).

Khởi đầu, mô hình dự đoán một hằng số (thường là giá trị trung bình của toàn bộ dữ liệu mục tiêu). Đương nhiên, dự đoán này rất tệ và tạo ra một phần sai số (Residual).

Ở bước tiếp theo, cây quyết định thứ nhất sẽ không học cách dự đoán giá trị mục tiêu gốc, mà nó sẽ học cách "dự đoán cái sai số" mà bước trước đã tạo ra. Mục đích là để bù trừ và sửa chữa lỗi lầm của mô hình trước đó.

Sau khi cây thứ nhất được thêm vào, dự đoán tổng cộng được cập nhật, và một sai số mới (nhỏ hơn) lại xuất hiện. Cây quyết định thứ hai tiếp tục được sinh ra chỉ để học cách dự đoán cái sai số mới này. Quá trình này lặp lại hàng trăm, hàng ngàn lần. Phương pháp tối ưu hóa để tìm ra cách kết hợp các cây này dựa trên thuật toán Gradient Descent (Hạ dốc) nhằm tối thiểu hóa một hàm mất mát (Loss Function).

Để ngăn chặn việc mô hình học thuộc lòng dữ liệu huấn luyện (Overfitting), Gradient Boosting sử dụng tham số Tốc độ học (Learning Rate - Shrinkage). Thay vì áp dụng 100% dự đoán của một cây mới vào tổng thể, nó chỉ nhân với một hệ số nhỏ (ví dụ 0.1). Điều này ép thuật toán phải sử dụng nhiều cây hơn, học từ từ, cẩn thận hơn, từ đó tăng khả năng tổng quát hóa trên tập dữ liệu chưa từng nhìn thấy (Test set).

Để đánh giá hiệu suất của mô hình hồi quy, nghiên cứu sử dụng hai thang đo chính:

- **R-Squared (R^2 Score):** Là hệ số xác định, biểu thị tỷ lệ phương sai của biến phụ thuộc có thể dự đoán được từ biến độc lập. Giá trị lý tưởng là 1.0. R^2 cho thấy mô hình của chúng ta phù hợp với dữ liệu đến mức nào.
- **Mean Absolute Error (MAE):** Tính giá trị trung bình của trị tuyệt đối các sai số giữa giá trị dự đoán và giá trị thực tế. MAE rất dễ diễn giải vì nó có cùng đơn vị với biến mục tiêu. Ví dụ: MAE = 15 có nghĩa là trung bình mô hình dự đoán lệch so với thực tế 15 chuyến xe.

2.4 Công cụ và Thư viện lập trình

Toàn bộ quy trình nghiên cứu được triển khai bằng ngôn ngữ lập trình Python, thông qua môi trường phân tích tương tác Jupyter Notebook. Đây là tiêu chuẩn vàng (gold standard) trong ngành công nghiệp Khoa học dữ liệu hiện tại.

- **Thư viện Pandas:** Là thư viện mã nguồn mở cung cấp cấu trúc dữ liệu DataFrame hiệu suất cao. Pandas cho phép nhập xuất dữ liệu dễ dàng từ file CSV, xử lý các thao tác truy vấn (query), lọc (filter), hợp nhất (merge) và đặc biệt là gom nhóm (groupby) dữ liệu một cách trực quan như ngôn ngữ SQL

nhưng linh hoạt hơn rất nhiều. Hầu như mọi bước tiền xử lý trong đề tài đều dựa trên năng lực của Pandas.

- **Thư viện NumPy:** Chuyên xử lý mảng đa chiều (arrays) và các phép toán ma trận phức tạp. NumPy là nền tảng cốt lõi mà Pandas và Scikit-Learn xây dựng dựa trên nó, đảm bảo tốc độ tính toán tối ưu nhờ việc biên dịch ngầm bằng C/C++.
- **Matplotlib và Seaborn:** Hai thư viện phụ trách khâu Trực quan hóa dữ liệu (Data Visualization). Matplotlib đóng vai trò như một bảng vẽ kỹ thuật số, cung cấp quyền kiểm soát cực sâu đến từng trục tọa độ, nét vẽ, màu sắc. Trong khi đó, Seaborn (được xây dựng trên nền Matplotlib) cung cấp các hàm vẽ biểu đồ thống kê mức cao (high-level API). Seaborn giúp vẽ các biểu đồ phức tạp như Boxplot, Heatmap hay phân phối chuẩn với giao diện mặc định vô cùng bắt mắt, giúp người nghiên cứu dễ dàng phơi bày các quy luật tiềm ẩn trong dữ liệu.
- **Scikit-Learn (Sklearn):** Thư viện máy học mạnh mẽ và toàn diện nhất của Python. Sklearn cung cấp hệ thống API đồng nhất cho hầu hết các thuật toán học máy từ Tiền xử lý (StandardScaler), chia tập dữ liệu (train_test_split) cho đến mô hình hóa (KMeans, GradientBoostingRegressor) và các hàm đánh giá độ đo (r2_score, mean_absolute_error). Việc thiết kế hệ thống của Sklearn hỗ trợ việc xây dựng các Data Pipelines tự động một cách vô cùng trơn tru.

Tóm tắt Chương 2

Chương 2 đã trang bị cơ sở lý thuyết vững chắc về cả quy trình lẫn thuật toán để giải quyết đề tài. Qua đó, quy trình CRISP-DM nhấn mạnh vai trò cốt lõi của bước Kỹ nghệ Đặc trưng (Feature Engineering) khi biến đổi thời gian thực thành các biến có ý nghĩa. Việc nắm vững hai thuật toán: K-Means (Học không giám sát, dùng khoảng cách Euclide để phân cụm) và Gradient Boosting (Học có giám sát, dựa trên sự kết hợp tuần tự của Cây quyết định nhằm tối ưu hóa sai số) là tiền đề để triển khai vào dữ liệu thực. Đi kèm với đó là bộ công cụ mạnh mẽ của Python (Pandas, Sklearn) đóng vai trò xúc tác tạo ra các phân tích định lượng ở chương tiếp theo.


CHƯƠNG 3: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

3.1 Phân tích thống kê mô tả: Hiểu về hành vi người dùng

Trong phần này, chúng ta tiến hành đi sâu vào Khai phá dữ liệu khám phá (EDA) thông qua việc phân tích thống kê để trả lời 5 câu hỏi nghiên cứu đầu tiên. Việc phân tích thống kê là bước đệm tối quan trọng, cung cấp cái nhìn trực quan và những phát hiện sơ bộ trước khi áp dụng các mô hình học máy phức tạp. Các kết quả biểu đồ được trình bày theo tông màu sáng, chuyên nghiệp nhằm tăng tính minh bạch và độ rõ nét cho ấn phẩm khoa học.

3.1.1 Phân tích chu kỳ nhu cầu theo khung giờ trong ngày

Thời gian trong ngày là một trong những biến số nhạy cảm nhất ảnh hưởng trực tiếp đến nhu cầu gọi xe. Hành vi con người gắn liền với nhịp sinh học và nhịp điệu kinh tế - xã hội của một đô thị. Để xác định rõ các khoảng thời gian cao điểm, toàn bộ 20,000 bản ghi dữ liệu đã được gom nhóm (groupby) theo đặc trưng "Giờ" từ 0 đến 23. Số lượng chuyến xe xuất hiện trong từng khung giờ được đếm tổng để vẽ biểu đồ tần suất.



Hình 3.1: Biểu đồ số chuyến đi theo khung giờ

Biểu đồ cột (Bar chart) kết hợp đường xu hướng (Trendline) đã phác họa rõ nét dạng sóng hình Sin đặc trưng của giao thông đô thị. Kết quả phân tích chỉ ra hai đỉnh cực đại rõ rệt trong biểu đồ. Đỉnh thứ nhất xuất hiện vào khung giờ sáng sớm (khoảng 7h00 - 8h30), tương ứng với thời điểm hàng triệu người lao động, học sinh, sinh viên bắt đầu chu kỳ di chuyển đến công sở và trường học. Đỉnh thứ hai, lớn hơn và kéo dài


hơn, diễn ra vào khung giờ chiều tối (từ 17h00 đến 19h00). Đây là khoảng thời gian tan tầm, khi mọi người đổ ra đường để trở về nhà hoặc di chuyển đến các địa điểm ăn uống, giải trí buổi tối.

Ngược lại, vùng trũng của đồ thị, tức là thời điểm có lượng đặt xe thấp nhất, nằm trong khoảng từ 2h00 sáng đến 5h00 sáng. Lúc này các hoạt động kinh tế gần như đóng băng. Việc xuất hiện lượng chuyển đi nhỏ giọt trong đêm khuya chủ yếu phục vụ các nhu cầu cấp thiết, chuyển bay đêm hoặc những người làm việc ca ba.

Nhận định chiến lược: Từ góc độ kinh doanh của hãng xe, đường cong này là kim chỉ nam cho việc điều hành. Hãng xe bắt buộc phải có các chính sách thưởng (bonus) hoặc nhân giá (surge) mạnh tay vào hai khung giờ cao điểm sáng và chiều để thu hút tài xế bật ứng dụng, đảm bảo tỷ lệ hoàn thành chuyến (fulfillment rate). Vào ban đêm, hãng có thể giảm số lượng tài xế hoạt động để tiết kiệm chi phí hệ thống hoặc áp dụng mức cước phí ban đêm cao hơn để bù đắp sự khan hiếm tài xế sẵn sàng làm việc.

3.1.2 Phân bố lưu lượng xe theo các ngày trong tuần

Sau khi phân tích theo quy mô giờ, chúng ta mở rộng lăng kính phân tích ra chu kỳ tuần. Liệu nhu cầu đi lại có sự chênh lệch giữa ngày làm việc trong tuần (Weekday) và ngày nghỉ cuối tuần (Weekend)? Việc thống kê dựa trên hàm groupby biến "Thứ trong tuần" và biểu diễn qua hai góc nhìn: Số tuyệt đối (Biểu đồ cột) và Số tương đối (Biểu đồ tròn phần trăm).



Hình 3.2: Phân bố số chuyến đi theo ngày trong tuần


Kết quả từ cả hai biểu đồ đã làm sáng tỏ một sự phân cực nhẹ trong tuần. Thứ Bảy và Chủ Nhật luôn duy trì vị thế dẫn đầu về tổng lượng chuyển đi, chiếm tỷ trọng cao nhất trên biểu đồ tròn (Pie Chart). Trong khi đó, các ngày giữa tuần từ Thứ Hai đến Thứ Tư có lượng khách ổn định ở mức thấp hơn. Thứ Sáu chứng kiến một sự bứt phá đáng kể, đóng vai trò như một ngày chuyển tiếp giữa nhịp điệu công việc căng thẳng và nhịp điệu giải trí cuối tuần.

Nguyên nhân của hiện tượng này có thể được giải thích qua hành vi người dùng tại TP.HCM. Trong các ngày làm việc, người dân có xu hướng di chuyển theo lộ trình cố định (nhà - công ty) và thường sử dụng phương tiện cá nhân (xe máy) do tính chủ động và chi phí thấp hơn. Tuy nhiên, vào các ngày cuối tuần, khi phát sinh nhu cầu đi chơi, mua sắm, dự tiệc, hẹn hò hoặc di chuyển cả gia đình, tâm lý người dùng thường muốn thoải mái, tránh khói bụi và tìm chỗ đậu xe khó khăn, do đó họ ưu tiên sử dụng dịch vụ đặt xe công nghệ (đặc biệt là dịch vụ Car 4 chỗ và 7 chỗ).

Nhận định chiến lược: Phát hiện này gợi ý cho bộ phận Marketing của hãng xe về việc thiết kế các gói khuyến mãi (Voucher). Thay vì tung ra khuyến mãi dàn trải, hãng nên tung các mã giảm giá mạnh vào các ngày thấp điểm (Thứ Ba, Thứ Tư) để kích cầu người dùng. Ngược lại, vào cuối tuần, người dùng đã có sẵn ý định và nhu cầu tự nhiên cao, việc cắt giảm khuyến mãi tại thời điểm này sẽ tối ưu hóa lợi nhuận. Hơn nữa, hãng cần khuyến khích các tài xế part-time (làm bán thời gian) hoạt động năng nổ hơn vào Thứ Bảy, Chủ Nhật để đáp ứng cơn khát xe của thị trường.

3.1.3 Trực quan hóa dữ liệu không gian và địa lý (Spatial Analysis)

Dữ liệu vận tải là dữ liệu có tính chất không gian (Spatial Data). Khác với các phân tích thời gian ở trên, phân tích không gian đòi hỏi chúng ta xác định tọa độ kinh tuyến, vĩ tuyến để lập bản đồ trực quan mật độ. Chúng tôi đã tiến hành đếm số chuyển theo từng khu vực (Quận/Huyện) và vẽ đồ thị Scatter plot dựa trên tọa độ Vĩ độ (Lat) và Kinh độ (Lon) thực tế.



Hình 3.3: Nhu cầu đặt xe theo từng Quận/Huyện


Biểu đồ cột ngang (Horizontal Bar Chart) bên trái cho thấy một sự chênh lệch khủng khiếp giữa các khu vực. Quận 1 và Tân Bình vươn lên chiếm thể thượng phong với số lượng chuyến đi áp đảo hoàn toàn các quận lân cận. Bản đồ Scatter plot bên phải cung cấp một góc nhìn chân thực như nhìn từ vệ tinh: các điểm chấm hội tụ thành những mảng màu đen đặc kịt tại vị trí lõi trung tâm của TP.HCM.

Sự tập trung dày đặc tại Quận 1 phản ánh vai trò "trái tim" kinh tế, tài chính, văn hóa của thành phố, nơi quy tụ các tòa nhà văn phòng hạng A, các trung tâm thương mại lớn và các tụ điểm du lịch sầm uất. Trong khi đó, mật độ cao tại khu vực Tân Bình được giải thích bằng sự hiện diện của Cảng hàng không Quốc tế Tân Sơn Nhất - nơi sản sinh ra một lượng cực lớn nhu cầu trung chuyển (transit) bằng xe công nghệ bất kể ngày đêm. Các quận vùng ven như Quận 7 hay Quận 2 có mật độ thấp hơn nhưng vẫn tạo thành các cụm tập trung mang tính chất các đô thị mới, khu dân cư cao cấp.

Nhận định chiến lược: Phân bổ tài xế không bao giờ nên đồng đều. Việc duy trì một lực lượng tài xế lớn túc trực tại các cung đường quanh Quận 1 và khu vực sân bay Tân Sơn Nhất là chiến thuật cốt lõi để giảm thời gian chờ của khách hàng xuống dưới 3 phút. Đối với các quận vùng ven, hãy cần áp dụng mô hình ghép chuyến (Carpooling) hoặc dịch vụ giao hàng, giao thức ăn để bù đắp vào thời gian rảnh rỗi của tài xế khi họ đưa khách từ trung tâm về vùng ven và chờ có chuyến quay ngược lại trung tâm.

3.1.4 Khảo sát phân phối cự ly di chuyển

Quãng đường di chuyển là thông số vật lý trực tiếp cấu thành nên giá cước và thời gian hao phí của tài xế. Hiểu rõ phân phối của quãng đường giúp phân loại các chuyến đi thành các tập: siêu ngắn, ngắn, trung bình và xa. Chúng tôi sử dụng Histogram (Biểu đồ phân phối tần suất) và Boxplot (Biểu đồ hộp) để đo lường các đặc trưng thống kê của quãng đường di chuyển (đơn vị: Kilomet).



Hình 3.4: Phân phối quãng đường các chuyến đi


Phân tích Histogram chỉ ra một dạng hình học rất điển hình trong thống kê: Phân phối lệch phải mạnh mẽ (Strong Right-skewed Distribution). Ngọn núi của đồ thị vút lên cao vút ở khu vực từ 1km đến 5km và trượt dốc nhanh chóng khi cự ly tiến về mốc 10km. Hầu như có rất ít các chuyến đi kéo dài trên 20km. Biểu đồ Boxplot bên phải xác nhận lại điều này, đường trung vị (chấm giữa hộp) nằm sát mốc 3-4km, và phần rìa phải của hộp xuất hiện dày đặc các chấm tròn đen - biểu thị cho các giá trị ngoại lai (outliers), tức là những chuyến đi xa bất thường.

Kết quả này vẽ lên chân dung đặc trưng của giao thông đô thị: Xe công nghệ chủ yếu phục vụ cho các kết nối chặng ngắn (Last-mile connection). Khách hàng sử dụng dịch vụ để đi từ nhà ra bến xe, từ trạm xe buýt về ngõ sâu, hoặc di chuyển giữa các tòa nhà văn phòng trong phạm vi hẹp nội thành nơi mà việc gửi xe cá nhân gặp nhiều bất tiện. Đối với những khoảng cách rất xa (như đi liên tỉnh), người dân có xu hướng ưu tiên xe khách hoặc phương tiện cá nhân vì vấn đề chi phí.

Nhận định chiến lược: Kinh doanh các chuyến đi ngắn đòi hỏi một hệ thống có tốc độ ghép cước cực nhanh. Doanh thu trên mỗi chuyến ngắn (revenue per trip) là nhỏ, nhưng tần suất xoay vòng xe (turnover) lại cực kỳ cao. Hãng cần thiết kế thuật toán ghép chuyến liên hoàn (tài xế chưa trả xong khách hiện tại đã nhận được lệnh đón khách mới ở ngay gần đó) để tối đa hóa số chuyến trong ngày. Ngoài ra, việc thiết lập mức giá sàn tối thiểu (minimum fare) là cực kỳ quan trọng để đảm bảo tài xế không bị lỗ vốn thời gian khi chạy những chuyến đi dưới 1km trong điều kiện kẹt xe.

3.1.5 Mối quan hệ tương quan Giờ - Ngày bằng Heatmap

Những phân tích đơn biến ở các phần trước là chưa đủ để nhìn thấy sự tương tác. Câu hỏi đặt ra là: Giờ cao điểm của ngày Chủ Nhật có giống với giờ cao điểm của ngày Thứ Hai hay không? Việc giải quyết câu hỏi này đòi hỏi chúng ta phải gom nhóm dữ liệu theo cả 2 trục: Trục tung là Ngày trong tuần và Trục hoành là Giờ trong ngày. Công cụ lý tưởng nhất để làm nổi bật ma trận 2 chiều này là Bản đồ nhiệt (Heatmap), nơi sức nóng của dữ liệu được mã hóa bằng sắc độ màu.



Hình 3.5: Mối quan hệ giữa thời gian và số chuyến (Heatmap)

Nhìn vào Heatmap, một thế giới dữ liệu thú vị mở ra rục rờ với các mảng màu cam tối. Ta dễ dàng nhận ra hai "khối" hành vi trái ngược hoàn toàn:

Khối Ngày thường (Thứ 2 đến Thứ 6): Bức tranh màu sắc thể hiện hai dải dọc màu đậm vô cùng rõ nét tại cột 7h-8h sáng và cột 17h-18h chiều. Dải dọc buổi chiều thường đậm hơn và lan rộng ra cột 19h. Bức tranh này lặp lại một cách máy móc và

đều đặn từ Thứ 2 đến Thứ 6, phản ánh kỷ luật lao động khắt khe của xã hội công nghiệp.

Khối Cuối tuần (Thứ 7, Chủ Nhật): Dải màu đậm buổi sáng (7h-8h) bỗng dung biến mất hoàn toàn, thay vào đó là một vùng màu nhạt. Điều này có nghĩa là vào cuối tuần, người dân có xu hướng ngủ nướng, thức dậy muộn và không có nhu cầu ra khỏi nhà sớm. Màu đậm bắt đầu dịch chuyển sang khu vực giữa trưa (11h-12h) khi mọi người đổ đi ăn uống cuối tuần. Đặc biệt, tại cột buổi tối và đêm muộn (từ 19h đến tận 23h), màu sắc rực rỡ và đậm đặc một cách bất thường so với ngày thường. Đây là lúc cuộc sống về đêm (nightlife), các rạp chiếu phim, quán bar, nhà hàng tiệc tùng hoạt động hết công suất.

Nhận định chiến lược: Heatmap là bảng cửu chương cho bộ phận vận hành. Các tài xế không nên được phân bổ theo một lịch trình cứng nhắc. Cần khuyến khích tài xế nghỉ ngơi vào sáng sớm cuối tuần và tập trung làm việc vào ca tối muộn cuối tuần. Các thông báo "Sắp có nhu cầu cao" phải được ứng dụng đẩy (Push notification) đến điện thoại tài xế vào các khoảng thời gian khác nhau tùy thuộc vào lịch trên Heatmap.

3.2 Ứng dụng Học Máy (Machine Learning) trong phân tích sâu


Vượt ra khỏi các phân tích thống kê chỉ mang tính giải thích quá khứ, chúng tôi tiến hành khai thác sâu bộ dữ liệu bằng các thuật toán Machine Learning. Mục đích là để máy tính tự động tìm ra các quy luật phức tạp ẩn sâu bên trong tọa độ và tự động hóa khả năng dự đoán tương lai – một yếu tố tiên quyết cho các hệ thống phần mềm thông minh.

3.2.1 Xây dựng mô hình dự đoán nhu cầu bằng Gradient Boosting Regressor

Chúng tôi xây dựng một bài toán hồi quy: Đầu vào (Input) là các thông tin về thời gian (Giờ nào? Thứ mấy? Có phải là ngày cuối tuần hay không?), Đầu ra (Output) cần dự đoán là Tổng số chuyến xe xuất hiện trong giờ đó.

Dữ liệu được chuẩn bị bằng cách tạo thêm các biến giả (dummy variables) để làm rõ đặc tính của ngày. Tập dữ liệu sau đó được xáo trộn ngẫu nhiên và phân tách theo tỷ lệ tiêu chuẩn: 80% dành cho huấn luyện (Training Set) và 20% dành cho kiểm thử (Testing Set). Thuật toán Gradient Boosting Regressor (GBR) được khởi tạo với số

lượng cây quyết định ($n_estimators$) là 100 và độ sâu tối đa của mỗi cây (max_depth) được tinh chỉnh ở mức phù hợp để tránh Overfitting.



Hình 3.6: Kết quả dự đoán số lượng chuyến xe

Kết quả chạy thực nghiệm mang lại những tín hiệu vô cùng khả quan. Biểu đồ Scatter (bên trái) biểu diễn trục X là Giá trị thực tế và trục Y là Giá trị mà mô hình GBR dự đoán. Một mô hình lý tưởng sẽ có các điểm chấm nằm hoàn hảo trên một đường thẳng góc 45 độ (đường $y=x$). Kết quả thực tế cho thấy các đám mây điểm hội tụ rất sát với đường chéo này, chứng tỏ khả năng học hỏi và bám sát quy luật rất ấn tượng của Gradient Boosting đối với dữ liệu giao thông phi tuyến tính.

Chỉ số sai số tuyệt đối trung bình (MAE) và Hệ số xác định (R2 Score) được tính toán trên tập Test cho kết quả ở mức chấp nhận được trong bối cảnh dữ liệu có nhiều biến động ngẫu nhiên.


Biểu đồ cột (bên phải) trích xuất một tính năng vô cùng mạnh mẽ của Gradient Boosting là Feature Importance (Độ quan trọng của đặc trưng). Bằng cách mổ xẻ nội bộ các cây quyết định, thuật toán tính toán và xếp hạng xem yếu tố nào ảnh hưởng nhiều nhất đến việc tăng giảm số chuyến xe. Kết quả xác nhận một cách thuyết phục rằng "Giờ trong ngày" là biến số thống trị mang tính quyết định tuyệt đối (chiếm trọng số cực lớn). Tiếp theo sau đó là "Tháng" và "Thứ trong tuần". Tính năng "Có phải cuối tuần không" mang trọng số nhỏ nhất do một phần tác động của nó đã bị hấp thụ bởi biến "Thứ trong tuần".

Nhận định chiến lược: Việc tích hợp một mô hình dự báo như GBR vào hệ thống backend sẽ mở ra cánh cửa cho tính năng Điều phối Chủ động (Proactive Dispatching). Thay vì chờ khách hàng mở app đặt xe rồi hệ thống mới cuống cuống đi tìm tài xế xung quanh, mô hình GBR sẽ liên tục chạy ngầm, dự báo trước lưu lượng 30 phút tới. Nếu hệ thống dự đoán sắp có một "cơn bão" yêu cầu tại một khu vực, nó sẽ âm thầm điều phối các xe trống gần đó từ từ di chuyển về hướng mục tiêu trước khi nhu cầu thực sự phát sinh, biến sự bị động thành chủ động hoàn toàn.

3.2.2 Phân cụm Surge Pricing bằng Thuật toán K-Means Clustering

Tăng giá động (Surge Pricing) là một nghệ thuật kinh doanh dựa trên dữ liệu. Hãng xe không thể tăng giá bữa bãi trên toàn thành phố, mà chỉ tăng giá tại đúng những khu vực đang thiếu hụt xe nghiêm trọng. Để máy tính nhận diện được các "vùng" này, chúng tôi chia bản đồ TP.HCM thành các ô vuông lưới nhỏ (grid) kích thước xấp xỉ 500m x 500m (làm tròn 0.005 độ kinh tuyến/vĩ tuyến). Sau đó đếm tổng số chuyến khởi phát trong mỗi ô lưới.

Thuật toán K-Means Clustering được áp dụng lên mật độ số chuyến này. Dữ liệu đầu vào trước tiên được đi qua hệ thống StandardScaler để chuẩn hóa phương sai. Số lượng cụm $K=3$ được thiết lập với mong muốn máy tính sẽ tự động gán nhãn cho các ô lưới thành 3 hạng: Hạng 1 (Nhu cầu Rất Cao), Hạng 2 (Nhu cầu Trung bình) và Hạng 3 (Nhu cầu Thấp).



Hình 3.7: Phân cụm các khu vực theo K-Means

Kết quả của thuật toán thực sự ngoạn mục khi thể hiện trên biểu đồ. Bản đồ phân cụm (Scatter plot bên trái) tự động vẽ ra 3 mảng màu rõ rệt trên địa hình TP.HCM mà không cần bất kỳ sự can thiệp thủ công nào. Cụm màu cam sáng đại diện cho các vùng "Lõi" trung tâm (Quận 1, Tân Sơn Nhất) có mật độ đặc kịt. Cụm màu xanh nhạt bao quanh lớp lõi tạo thành lớp đệm nhu cầu trung bình. Cụm màu xanh đậm nằm rải rác ở các vùng rìa ngoại ô biểu diễn các khu vực có nhu cầu rất thưa thớt.

Biểu đồ cột (bên phải) cho thấy sự chênh lệch khủng khiếp về trị số trung bình của 3 cụm. Cụm nhu cầu cao (Cụm 0) có trung bình hàng trăm ngàn chuyến, cao gấp hàng chục lần so với cụm nhu cầu trung bình và thấp. Máy học đã làm thay con người việc vẽ ranh giới phức tạp bằng một đường biên toán học vô hình.

Nhận định chiến lược: Đây là trái tim của hệ thống Surge Pricing. Khi bản đồ phân cụm này được chạy real-time (cập nhật mỗi 5 phút một lần), hệ thống sẽ chiếu tọa độ hiện tại của hành khách đặt xe xem họ đang đứng ở cụm màu nào. Nếu nằm ở cụm màu cam (Nhu cầu Cao đột biến), một hệ số nhân giá (ví dụ: 1.5x, 2.0x) sẽ ngay lập tức được cộng dồn vào giá cước cơ bản. Việc tăng giá này không nhằm mục đích "bóp nghẹt" khách hàng, mà là sử dụng bàn tay vô hình của giá cả kinh tế học để tạo ra động lực kinh tế cực lớn, hút như nam châm toàn bộ tài xế từ các vùng xanh (nhu cầu thấp) chạy vào vùng cam để giải cứu khách hàng.

Tóm tắt Chương 3

Chương 3 là phần cốt lõi của nghiên cứu, nơi dữ liệu lên tiếng. Từ các phân tích thống kê truyền thống, chúng ta phát hiện những quy luật mạnh mẽ về thời gian (đỉnh cao sáng chiều, sự trỗi dậy của cuối tuần) và không gian (sự áp đảo của Quận 1 và khu vực sân bay Tân Sơn Nhất). Quan trọng hơn, thông qua hai thuật toán Học máy, nghiên cứu đã chứng minh khả năng tự động hóa trong việc dự đoán số chuyến đi (bằng Gradient Boosting) và phân loại bản đồ để xây dựng giá Surge (bằng K-Means). Những phát hiện này trực tiếp trả lời các câu hỏi nghiên cứu ban đầu và là tiền đề vững chắc cho mọi đề xuất giải pháp ở phần Kết luận.

CHƯƠNG 4: KẾT LUẬN VÀ KIẾN NGHỊ GIẢI PHÁP

4.1 Kết luận chung

Nghiên cứu "Phân tích và khai thác dữ liệu đặt xe công nghệ tại TP.HCM" đã hoàn thành xuất sắc các mục tiêu đề ra ban đầu. Xuyên suốt quá trình nghiên cứu, việc áp dụng bài bản các công cụ Phân tích Khoa học Dữ liệu bằng ngôn ngữ Python (Pandas, Numpy, Seaborn) đã phơi bày hàng loạt các tri thức kinh doanh bị ẩn giấu dưới lớp dữ liệu khổng lồ.

Những phát hiện định lượng cốt lõi bao gồm: Sự tồn tại của chu kỳ nhu cầu hình Sin với đỉnh sóng vào 7h sáng và 18h chiều; sự dịch chuyển thói quen di chuyển từ giờ hành chính ngày thường sang các hoạt động giải trí buổi trưa và đêm muộn vào cuối tuần; sự tập trung nhu cầu cực đoan tại vùng không gian lõi trung tâm (Quận 1, Tân Bình); và đặc thù "chặng ngắn" của giao thông xe công nghệ với đại đa số các chuyến đi có cự ly dưới 5km.

Thành công nổi bật nhất của đề tài là việc không dừng lại ở mức độ phân tích quá khứ, mà đã tự tin bước chân vào lĩnh vực Học máy (Machine Learning). Mô hình Gradient Boosting Regressor đã chứng minh được tính hiệu quả trong việc nắm bắt quy luật phi tuyến tính để dự báo số chuyến. Mô hình K-Means Clustering đóng vai trò như một bộ phân cực tự động, chia cắt không gian đô thị thành các cấp độ nhu cầu một cách tự nhiên và chính xác nhất.

4.2 Kiến nghị giải pháp mang tính chiến lược

Từ kết quả nghiên cứu và sự am hiểu về bối cảnh kinh doanh, nhóm thực hiện xin đề xuất một chuỗi các giải pháp kiến nghị mang tính hệ thống dành cho ban lãnh đạo các tập đoàn điều hành mạng lưới xe công nghệ:

- Giải pháp Tối ưu hóa Nguồn nhân lực linh hoạt (Flexible Resource Allocation): Căn cứ vào bản đồ nhiệt (Heatmap), cần có một cơ chế "Giao ca tự động". Khuyến khích mạnh mẽ một bộ phận tài xế chuyển sang làm việc "Ca gãy" (chỉ chạy từ 6h-9h và 16h-20h) bằng các chính sách thưởng doanh thu đột phá. Thay vì làm việc 12 tiếng liên tục với hiệu suất thấp vào giữa trưa, việc chạy ca gãy

mang lại thu nhập cao hơn cho tài xế và giải quyết dứt điểm bài toán thiếu xe cho hệ thống.

- Giải pháp Điều hành Chiến dịch Marketing vi mô (Micro-Marketing): Chấm dứt việc phát hành khuyến mãi dàn trải toàn thành phố. Kích hoạt các chiến dịch khuyến mãi nhắm mục tiêu địa lý hẹp (Geo-fencing Promotion). Đẩy mã giảm giá cho các chuyến đi có điểm xuất phát ở các vùng rìa (Cụm K-Means số 2) vào giờ thấp điểm để kích cầu. Cắt toàn bộ khuyến mãi tại các khu vực đang là điểm nóng (Cụm K-Means số 0).
- Giải pháp Tích hợp Trí tuệ nhân tạo (AI Integration): Nhanh chóng đưa hai mô hình Machine Learning được nghiên cứu trong bài báo cáo này (Gradient Boosting và K-Means) từ môi trường thử nghiệm (Jupyter Notebook/Local) lên môi trường triển khai thực tế (Production). Xây dựng một hệ thống Pipeline tự động cập nhật và huấn luyện lại (Retrain) mô hình vào mỗi nửa đêm. Điều này đảm bảo thuật toán định giá Surge Pricing và hệ thống điều hướng tài xế luôn phản ứng chính xác với mọi biến động nhỏ nhất của đời sống giao thông đô thị.

Việc ứng dụng nghiêm túc Khoa học Dữ liệu không chỉ mang lại lợi thế cạnh tranh áp đảo về mặt công nghệ, tối đa hóa lợi nhuận cho doanh nghiệp mà còn góp phần không nhỏ vào việc giải tỏa áp lực giao thông, mang lại trải nghiệm di chuyển tiện lợi, hiện đại cho người dân Thành phố Hồ Chí Minh.

TÀI LIỆU THAM KHẢO

- [1] McKinney, W. (2012). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media.
- [2] VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media.
- [3] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [4] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of statistics*, 1189-1232.
- [5] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*.